



姓名：张伟

邮箱：3125532621@qq.com

民族：汉族

政治面貌：共青团员

电话：18856077866

毕业院校：东南大学

教育背景

2016.09~2020.06	天津工业大学	电子信息工程	本科
2022.09~2025.06	东南大学	电子信息	硕士

工作经历

公司：华为南京研究所 岗位：通用软件开发工程师 起止时间：2025.07~至今
DeepSeek-V4 分布式训练与昇腾 NPU 算子适配

技术栈：PyTorch、torch-titan-npu、CANN、DTensor、HCCL

● 上下文并行 (CP) 切分

设计并实现 Window、C4A、C128A 三类注意力的序列切分方案，使用 P2P 边界交换及压缩 KV 的 AllGather/ReduceScatter 实现前反向通信；修正全局 RoPE 位置、因果掩码和稀疏索引，处理反向通信不对称、索引偏移与张量维度不一致问题。

● 流水线并行 (PP) 切分

分两阶段完成 PP 适配：先针对 mHC 出口聚合不兼容通用切分的问题，实现专用切分，保留末 stage 的 hc_head 并透传 input_ids；后将 hc_head 从模型顶层移入最后一个 Transformer 层，在层内完成聚合，复用 TorchTitan 通用 PP 切分并对齐 FSDP 参数聚合时机，同步更新 TP 计划与 HF 权重映射，删除约 150 行专用切分与校验逻辑。

● SwigluGroup 融合算子与低精训练适配

针对专家激活多算子串联的读写开销，接入 swiglu_group 融合 clamp、SwiGLU 及可选路由权重乘法；通过量化专家继承融合前向并协调配置转换顺序，兼容低精训练、避免重复量化。针对激活拼接反向切片产生的非连续梯度与符号形状引发的 AOTAutograd 构图报错，移除量化分支中数据依赖的连续性判断，打通前反向路径。

● MXFP8/MXFP4 量化权重加载

支持 DeepSeek-V4 直接加载 MXFP8/MXFP4 压缩权重，通过 DCP 按需读取分片，处理 FP4 逻辑形状与偏移映射、scale 校验及非对齐切片；调用 NPU 反量化算子，将结果写入目标参数，省去整份权重预先离线转换为浮点文件的步骤。加载后的训练精度由独立配方控制，可衔接 BF16 或低精训练。

自我评价

- 具备较强的学习与问题定位能力，围绕分布式训练中的通信、梯度和算子兼容问题开展分析与改进。熟悉 PyTorch 及昇腾 NPU 开发，具有 CP/PP 切分、融合算子接入与工程适配经验。重视代码质量、测试覆盖和协作沟通，工作认真负责，能够主动推动问题解决。已通过 CET-6，具备良好的英文技术文档阅读能力。