



姓名：张伟

民族：汉族

电话：18856077866

邮箱：3125532621@qq.com

政治面貌：共青团员

毕业院校：东南大学

教育背景

2016.09~2020.06天津工业大学电子信息工程本科

2022.09~2025.06东南大学电子信息硕士

工作经历

公司：华为南京研究所

岗位：通用软件开发工程师

起止时间：2025.07~至今

DeepSeek-V4 分布式训练与昇腾 NPU 算子适配

技术栈：PyTorch、torchitan-npu、CANN、DTensor、HCCL

- 上下文并行 (CP) 切分**

设计并实现 Window、C4A、C128A 三类注意力的序列切分方案，使用 P2P 边界交换及压缩 KV 的 AllGather/ReduceScatter 实现前反向通信；修正全局 RoPE 位置、因果掩码和稀疏索引，处理反向通信不对称、索引偏移与张量维度不一致问题。
- 流水线并行 (PP) 切分**

适配跨 stage 的 input_ids 透传，解决 MoE hash routing 丢失 token ID 与末 stage 缺少 hc_head 的问题；将 hc_head 移入最后一个 Transformer layer，复用通用 PP 切分并匹配 FSDP 参数聚合时机，同步更新 TP 计划及 HF 权重映射，减少约 150 行专用切分和校验逻辑。
- SwigluGroup 融合算子接入**

面向昇腾 A5 接入 SwigluGroup，融合路由专家与共享专家中的 clamp、SwiGLU 和可选路由权重乘法；通过独立 ModelConverter 切换激活实现，保持专家参数、权重布局 and checkpoint key，增加平台、依赖及 converter 顺序校验，补充参数状态保持与算子接线的单元测试。
- 原地 Partial RoPE 算子接入**

接入 inplace_partial_rotary_mul，通过独立 ModelConverter 替换 partial RoPE 入口；复用预计算 cos/sin 缓存，原地更新指定旋转区间，减少临时张量分配与拼接读写。适配 positions、inverse 和输入形状，补充缓存及配置隔离测试，保持原 npu_rope 路径兼容。

自我评价

- 具备较强的学习与问题定位能力，围绕分布式训练中的通信、梯度和算子兼容问题开展分析与改进。熟悉PyTorch及昇腾NPU开发，具有CP/PP切分、融合算子接入与工程适配经验。重视代码质量、测试覆盖和协作沟通，工作认真负责，能够主动推动问题解决。已通过CET-6，具备良好的英文技术文档阅读能力。